合成音声に朗読表現を付加するシステムの検討

福知山公立大学 情報学部情報学科

32145042　小山実生

指導教員　橋田光代

提出日　2025 年 1 月 31 日

目次

1 はじめに 1

2 音を通じたことばの表現 1

2.1 文章表現の曖昧さ 1

2.2 発話制御による自然な情報伝達と感情表現 . 1

2.3 話者による解釈違いを楽しむ朗読表現 2

3 関連研究：合成音声ツールの現状 2

3.1 VOICEPEAK 2

3.2 A.I VOICE2 Editor 3

3.3 朗読表現制御の課題 3

4 朗読表現支援システム 3

4.1 システムの機能 4

4.2 VOICEPEAK のデータ構造 4

4.3 処理の流れ 4

4.3.1 ファイルの読み込み

4.3.2 表現の付随

4.3.3 音声調節

5 適用事例 5

5.1 対象作品 5

5.2 手順 5

5.3 朗読表現の簡易な操作（はどの程度できたのよ？） 5

5.4 複数解釈による朗読表現（はどの程度できたのよ？） 5

6 まとめ 6

7 おわりに 6

図目次

1 音で伝える「頭が赤い魚を食べる猫」（文献を元に筆者作成） 1

2 異なる話者による『走れメロス』のスペクトログラム 2

3 VOICEPEAK 3

4 VOICEPEAK のパラメータ表示 3

5 A.I VOICE2 Editor 3

6 A.I VOICE2 Editor のパラメータ表示 3

7 ソフトウェア状でのパラメータ表示 3

8 A.I.VOICE2 でのアクセントの指定 4

9 システムのフローチャート (旧版：後日更新予定) 4

10 システムの画面１ 5

11 システムの画面２ 5

12 システムの画面３ 5

13 システムの画面４ 5

14 分析対象のテキスト 5

表目次

1 voicepeak 内部ファイルのキー 4

1. はじめに

人々は言葉をもってコミュニケーションを行っているが、人が話す言葉には、文章自体の情報と発話された音声が含まれている。そのうち音声の部分は、文章のみでは伝わりにくい曖昧な部分を音で固定・補完をする役割をもっている。例えば「頭が赤い魚を食べる猫」[1] という文章があった場合、文章に対し音の区切りや抑揚を適切につけることで「頭が赤い」のは「猫」なのか「魚」なのかが分かりやすくなる。また、音声の抑揚や強さ、速さを調節することで情報伝達だけでなく、話者の感情や解釈を伝えることができる。例えば「成功して良かったね」という文章に対し、はつらつと読むと嬉しそうな印象が伝わるが、平坦に読むと冷たい印象が伝わる。このように、人の発話には豊かな表現力が備わっている。

人の発話による音表現のひとつに朗読がある。朗読は報道機関でのアナウンスや公共施設での音声案内とは違い、情報伝達だけではなく音の表現にも重きを置かれる。そのため、朗読には音を鑑賞する測面も持ち合わせているとも考えられる。同じ文章でも、異なる話者が読み上げると全く違う発話表現が為されているからこそ、数多くの声優やナレーターが存在し、同じ演目の朗読劇が何度も催されているのではないだろうか。

本研究では、同じ文章でも異なる音の表現を生み出し、朗読のような発話表現に重きを置かれた音声を作りだせるシステムを作りたいと考え、既存の合成音声生成ソフトウェア『VOICEPEAK[2]』をベースに Python にてシステム構築を行った。また、発話表現に重きを置いた音声を生み出すだけではなく、ユーザに音声表現を設定させる機能を設けることで、出力される音声の多様化を図った。

2. 音を通じたことばの表現

2.1 文章表現の曖昧さ

ことばは、情報を的確に・時空を超えて・遠く・大勢に伝えるための記号として人間社会の中で言語が発展し体系化された。ことばの表現には、その自体の内容を伝える「情報」と発話された「音」の二つが含まれている。一般には、ことばの表現には情報が正しく伝わる文章力の側面が強く重視される。一方、文章のみでは文脈が伝わりにくい状況も発生する。では、文脈がややこしくなる文章を伝えやすくする文章上の工夫にはどのようなものがあるだろうか。

(1) 言葉の係り受けの整理

係り受けとは、日本語の文法において、単語や文節がどのように関係し合い、文全体の意味を構成するかを示す概念である。具体的には、「係り」成分 (修飾語) と「受け」成分 (被修飾語) の関係を整理することで、文章の構造や意味を明確にする。頭が赤い魚を食べる猫　という文章に対し、どこまでが「係り」成分でどこからが「受け」成分なのかを分析することで意味を明確にすることができる。

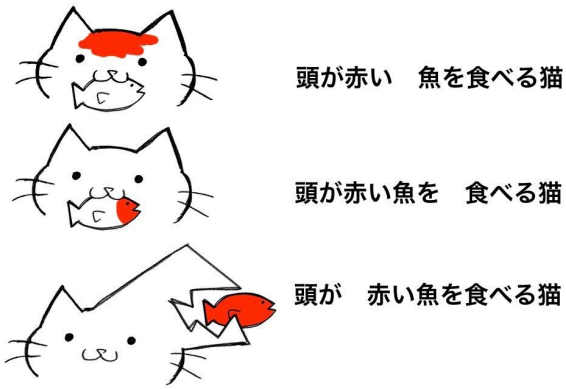

図 1: 音で伝える「頭が赤い魚を食べる猫」（文献を元に筆者作成）

(2) 句読点や行間の工夫

日本語は漢字、ひらがな、カタカナが混在した言語であるため、情報量が多くなる。そこで句読点や行間を文章に折り込むことで文字の密集を防ぎ、視覚的に読みやすくする。また、段落や内容の変わり目を分かりやすくする効果も期待できる。

2.2 発話制御による自然な情報伝達と感情表現

人々はコミュニケーションをとるうえで、文を音に乗せて発話することで相手に情報を伝える。この人の発話した音声には、文章自体の内容を伝える「情報」と発話された「音」の二つが含まれている。このうちの「音」には、文章のみでは伝わりにくい曖昧な部分を固定・補完する役割を持っている。

例えば「頭が赤い魚を食べる猫」という文章 [1] では，文章のみであると、「頭が赤い」という単語はどの名詞を説明しているのかが一見分かりにくい。また、「食べて」いるのは「猫」ではなく「猫の頭」という解釈もすることができる。こういった複数の解釈が生まれかねない文章に対し、音の区切りや抑揚等の「音」を適切に付随させることで、「赤い頭」をしているのは「猫」なのか「魚」なのか、はたまた「食べる」のは「猫」なのか「猫の頭」なのかが相手に伝わるようになる。このように、「音」には文章を固定・補完させる役割があると考えられる。

人の発話による音声表現の塩梅は、話者によってかなり変わってくる。**図 2** は、全く同じ文章を読み上げている、異なる話者 (いずれも男性) による朗読音声 [2], [3] をスペクトログラムで表したものである (図 2)。

これらは Python のライブラリのひとつである『Librosa[4]』を使って出力した。文章は、太宰治作『走れメロス [5]』の冒頭『メロスは激怒した。必ず、かの邪知暴虐の王を除かなければならぬと決意した。』という部分を読み上げている。スペクトログラムとは、音の高さ、音色、大きさ、長

© 2023-2025 Department of Informatics, The University of Fukuchiyama, Japan

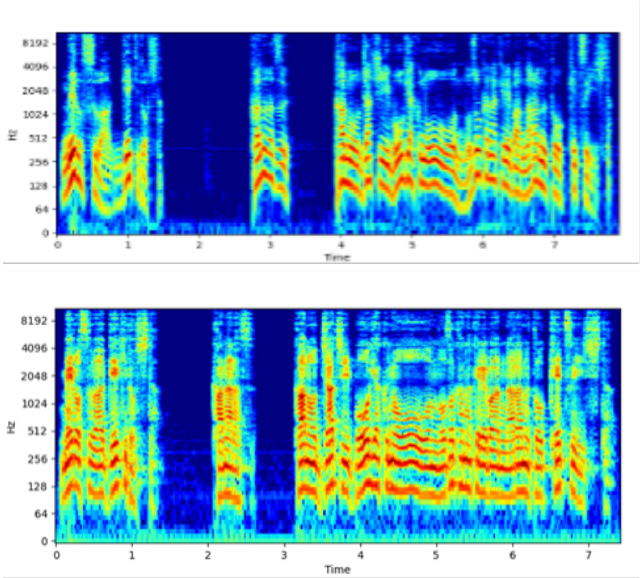

図 2: 異なる話者による『走れメロス』のスペクトログラム

さといった音の四要素を表す短時間フーリエ変換の表示であり、図の横の長さが時系列、音の強さを濃淡、波形の動きが音高やその移り変わりを示している。これら二つの図から、同じ文章でも話者が変われば全く違う音声が生まれていることが分かる。

また、それぞれのスペクトログラムに波形の動きが途切れている箇所が二つあるが、それらは文章の合間の『、』と『。』の部分を表している。これらからも、話者によって文の合間をどのくらい空けるかが変わっている。つまり、間の持たせ方も話者の持つ表現や解釈によって変わるのである。同じ文章でも話者の表現や解釈ごとに朗読が変化するのである。

音声の発話表現には読む速さや高さ、抑揚、強さ、単語のイントネーションなど、多くの要素がある。これらを細かく適切に調節することで、正確な情報伝達だけでなく話者の感情や意思を伝えることができる。例えば、「成功して良かったね」という文章があったとする。この文章に対し、声を高くはつらつと読むと嬉しそうな印象が伝わり、話者もまた成功を喜んでいることを伝えられる。一方、抑揚をあまり付けず平坦に読むと冷たい印象になり、言葉裏に話者自体は「良かった」とあまり思っていない、もしくはどうでも良さそうなイメージを聞き手に伝えられる。音声に含まれる感情には、コミュニケーションにおける話し手が実際に抱いている主観的なものと、感情表現を客観的に聞き手に共有されるステレオタイプの二つが考えられる**?**。そして、感情表現は日常におけるコミュニケーションだけでなく、音を豊かに表現する朗読においても重要な要素の一つとも言える。登場人物のセリフや心情などが描写された文章に感情的な表現を入れて読むことで、聞き手の物語に対する没入感がかなり変わる。

2.3　話者による解釈違いを楽しむ朗読表現

朗読の定義

ことばの表現のひとつに朗読がある。朗読の定義は様々だが、他者に文章内容を聞かせるために発音するものである。発声された文章によって、聞く者にイメージや情念を喚起させるようにいわゆる「表現として」読むことであると考えられている。音楽や美術の鑑賞と同じように、ただ聞き手に情報を与えるだけではなく、聞き手のこころに響かせるひとつの芸術として捉えられる。筆者には朗読の経験があり、朗読表現をつけるために様々な練習をしていた。例えば、「あー」という音を一分間、同じ音量、音程、強さをキープしながら出し続ける練習だったり、外郎売**?**を読んで滑らかに発声できるようにする練習など、朗読に向けて数多くの練習を行った。その中のひとつに、読み上げる原稿に対してブレスする箇所、間を空ける箇所を前もって決める作業があった。この作業をすることで、話者は息継ぎをする場所を決められたり、どの部分に余韻を持たせるかを考えることができる。これらの考えを活かし，本研究ではユーザによって異なる朗読表現が作成されるシステムを構築する

3.　関連研究：合成音声ツールの現状

合成音声とは、コンピュータなどを用いて人間の発話を真似た音声を人工的に生成されたもので、任意の文章を音声に変換して様々なことを発話させることができる。コンピュータから作り出せる音声として、単語単位を録音して作り出せる録音編集方式や、子音と母音を繋ぎ合わせて出力する規則音声方式などがある。また近年では深層学習 (DNN) に基づいた合成音声も開発 [6] され、発話の品質は高くなっている。

さらに、感情表現のついた合成音声に関する研究も進められており [7], [8], **?**、感情のついた合成音声を生成できるソフトウェア [9], [10] やツール [11] も数多く存在している。以下，既存のソフトウェアを用いてどれだけ朗読表現を行うことができるか，VOICEPEAK[9] と A.I.VOICE2 Editor[10] を例に試行する．

3.1　VOICEPEAK

VOICEPEAK[9] とは、株式会社 AHS によって開発・提供されている TTS(text to speech) の合成音声生成ソフトウェアである (**図 3**)。読ませたいテキストを入力するだけで合成音声を出力させることができる。また、合成音声を簡単な操作で出力できるだけではなく、音声表現を自分好みに調節することができる。ここで言う音声表現とは声質ではなく、イントネーションやアクセント、音の長さや強さなどといったものを指している。VOICEPEAK では、一音ごとのアクセント、イントネーション、音の区切り、長さなどの細かい調節も画面上から直感的に操作することが可能

© 2023-2025 Department of Informatics, The University of Fukuchiyama, Japan

図 3: VOICEPEAK

図 5: A.I VOICE2 Editor

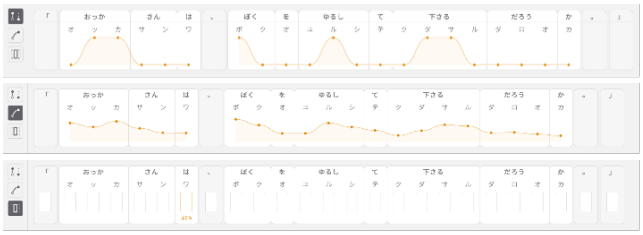

図 4: VOICEPEAK のパラメータ表示

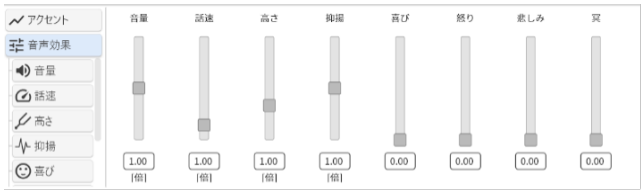

図 6: A.I VOICE2 Editor のパラメータ表示

である (図 4)。また、文章全体やブロック毎での読む速さやピッチも調節可能であり、感情表現 (幸せ 悲しみ 怒り 楽しみ) も付随させることができる。そのため、自動的に出力されたものより豊かな表現力のついた合成音声を作成することが可能である。

3.2 A.I VOICE2 Editor

A.I.VOICE2 Editor[10] とは、株式会社エーアイが提供している音声合成ソフトである (図 5)。音声合成 AITalk[12] の技術を応用した個人利用者向けソフトウェアで、簡単な操作で入力したテキストをキャラクターの自然な音声合成で読み上げ、音声ファイルとして作成することが可能である。テキストを読むキャラクターも数多く展開されており、声色を好みに合わせて選択できる。このソフトウェアは、アクセントとイントネーションの調節はいっしょくたにされているものの、音声全体やブロック毎の音量や読む速さ、高さ、抑揚、感情表現などのパラメータを具体的な数値で入力できる (図 6)。また、キャラクター独自の話し方で他のキャラクターの声色で発話させることができる『ボイスフュージョン機能』も A.I.VOICE 2 の大きな特徴と言える。

3.3 朗読表現制御の課題

VOICEPEAK はテキストを入力するだけで、合成音声が自動で作成される。また、合成音声を手軽に作成するだけでなく、文章全体の感情や文章ブロックごとの感情調節、一音ずつのアクセント、イントネーション、音の区切り、長さを細かく指定することも可能であり、より豊かな表現

図 7: ソフトウェア状でのパラメータ表示

力のついた合成音声を作成することができる。

しかし、音声表現をソフトウェア上から調節する場合、調節方法はマウスポインターをドラッグ・クリック操作で描写されたグラフやバーを直接動かすしか方法がない。つまり、一つ一つの調整をするのに時間がかかる。また、操作をすると数値が表示されるが、いくつかの値を横着する挙動が見受けられる (図 8)。さらに、パラメータによっては数値が表示されないものもあり、変更前と変更後でどのくらい値が変わったのかが分からない場合が出てくる。

また、A.I.VOICE2 で音声を調整する場合、アクセントの指定はできるものの、文章全体のイントネーションの流れはシステム側で設定される (図 ??)。そのため、ユーザから細かいイントネーションの設定をすることは不可能である。

4. 朗読表現支援システム

本章では、自身が組んだシステムについて述べる。本研究では、内部で作られるファイルの分かりやすさや理解のしやすさをふまえて VOICEPEAK を土台にシステム開発を行うことにした。そのため，VOICEPEAK のソフトウェ

© 2023-2025 Department of Informatics, The University of Fukuchiyama, Japan

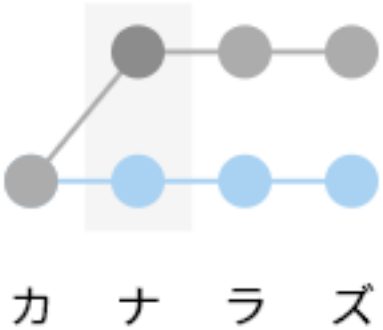

図 8: A.I.VOICE2 でのアクセントの指定

ア[*1]、及び VOICEPEAK によって作成された vpp 形式のファイルがデバイス上にあることを前提とする。

4.1 システムの機能

本研究システムでは文章の間の取り方を対話形式で提案している。間の取り方については、6 人の話者による朗読音声を参考に筆者が間の空け方を調べ、データ化したものから提案する。これにより、ユーザ毎に異なる表現の多様化を図っている。また、全体的なピッチの高さ、読み上げる速さについては、システム側からおすすめの値の範囲を示したうえで、ユーザに設定してもらう。

4.2 VOICEPEAK のデータ構造

VOICEPEAK 上で作成されたファイルは、vpp 形式で保存される。vpp ファイルの実態は JSON 形式であるため，Python 上で直接的にファイルの入出力をすることが可能である。

これらの結果をふまえ、本システムでは vpp ファイル内に含まれている、欲しい値が格納されている階層を検索して具体的な数値を表示、及び書き換えて保存することで Python 上から VOICEPEAK の合成音声の表現を変えられるようにした。

4.3 処理の流れ

本システムは，コマンドラインで稼働する CUI システムとして実装する．起動すると、コマンドラインから VOICEPEAK の音声を流すモードと、vpp ファイルの音声表現を操作するモードの二つを選ぶ場面が出てくる。VOICEPEAK には、140 字以内のテキストをコマンドラインからの指示で読ませることができ、1 を選ぶとテキストを入力するだけで音声がその場で再生される。しかし、コマンドラインから指示できるのは 140 字以内のテキストと読ませるナレーターの声色と 4 種類の感情表現の設定のみとなっており、VOICEPEAK が本来できることに比べてかなり簡略化されたものとなっている。

[*1] 『VOICEPEAK 商用可能 6 ナレーターセット』，https://xxx

表 1: voicepeak 内部ファイルのキー

project	プロジェクト全体に関わる設定が含まれる
params	話者全体に共通する調整パラメータ
speed	話速
pitch	音高
pause	ポーズの長さ
volume	音量
emotions	話者の感情パラメータ (例: happy, angry, sad, など)
s	トークンの文字列 (例: ’ 銀河’)
pos	品詞情報 (例: 4096)
lang	言語コード (例: 0)
pe	省略形かどうか (例: False)
syl	音節情報のリスト
syllable data	音節ごとのデータ
ig	音節が有効か (例: True)
a	アクセントの強弱 (8193: 強, 8192: 弱)
i	ピッチの調整値 (例: 0.0; 範囲は -3.0〜+3.0)
u	無声かどうか (例: False)
p	音声要素のデータ (例: 子音や母音)
sentence-ranges	文中のトークンのインデックス範囲

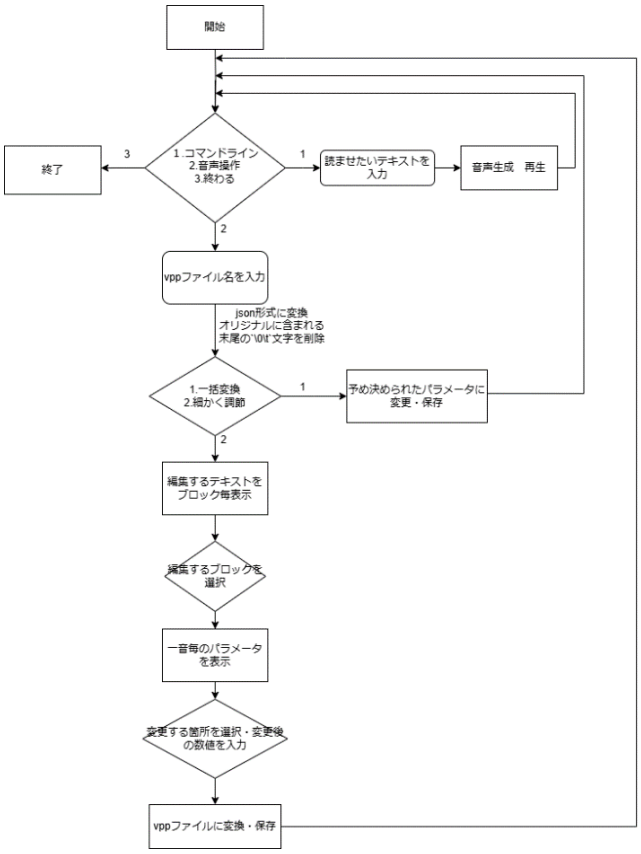

図 9: システムのフローチャート (旧版：後日更新予定)

4.3.1 ファイルの読み込み

まず、vpp 形式のファイルを json 形式に変換し、オリジナルに含まれている不要な末尾の文字を削除する。これをすることで読み込む際にエラー表示がされなくなる。

© 2023-2025 Department of Informatics, The University of Fukuchiyama, Japan

図 **10:** システムの画面 1

図 **11:** システムの画面 2

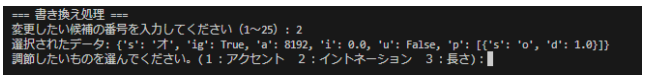

図 **12:** システムの画面 3

4.3.2　表現の付随

テキスト全体の読む速さ、ピッチの高さ、ポーズの長さを予め設定した値に一括で変更することで、デフォルトで生成されるものより表現力のついた合成音声を作ることができる。また、ここでの設定は読む速さを 85 %、ピッチの高さを-40 %、ポーズの長さを 105 %に変更している。尚、短ポーズ (「、」) と長ポーズ (「。」) の区別をつけて変更することは不可能である。

4.3.3　音声調節

２の「細かく調節」を選ぶと、読み込まれたファイルのテキストがブロック毎に表示される。

また、調節したいブロックの番号を選択することで、該当ブロックに含まれるテキストの、一音ずつのパラメータが表示される。

データは左からテキスト、アクセント (有:8193 無:8192 他:4096)、イントネーション (デフォルト値 0.0)、音声要素のデータ (このうち’d’は音の長さ) を示している。格納されているデータから必要な値だけを取り出して表示している。操作したいデータを候補の数字から選ぶことで、以下の図のようになる。

本研究システムでは、アクセント イントネーション 長さのいずれかを調節できるようにした。例えばイントネーションを 0.0 から 0.65 に変更したい場合、２を選択した後

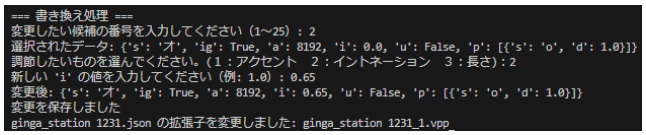

図 **13:** システムの画面 4

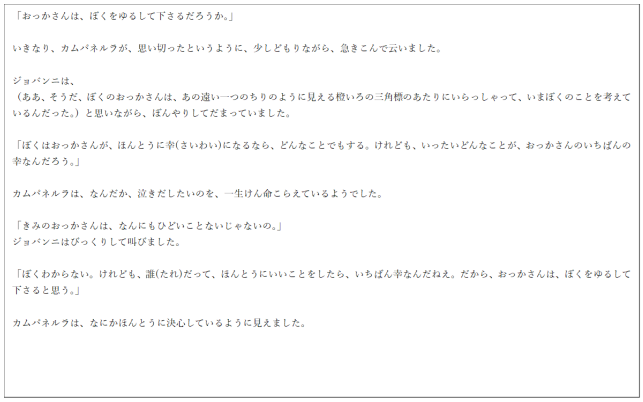

「おっかさんは、ぼくをゆるして下さるだろうか。」

いきなり、カムパネルラが、思い切ったというように、少しどもりながら、急きこんで云いました。

ジョバンニは、
（ああ、そうだ、ぼくのおっかさんは、あの遠い一つのちりのように見える橙いろの三角標のあたりにいらっしゃって、いまぼくのことを考えているんだった。）と思いながら、ぼんやりしてだまっていました。

「ぼくはおっかさんが、ほんとうに幸(さいわい)になるなら、どんなことでもする。けれども、いったいどんなことが、おっかさんのいちばんの幸なんだろう。」

カムパネルラは、なんだか、泣きだしたいのを、一生けん命こらえているようでした。

「きみのおっかさんは、なんにもひどいことないじゃないの。」
ジョバンニはびっくりして叫びました。

「ぼくわからない。けれども、誰(たれ)だって、ほんとうにいいことをしたら、いちばん幸なんだねえ。だから、おっかさんは、ぼくをゆるして下さると思う。」

カムパネルラは、なにかほんとうに決心しているように見えました。

図 **14:** 分析対象のテキスト

に 0.65 を入力することで値が変更される。これを終了まで繰り返すことで、調節が可能となっている。

5.　適用事例

5.1　対象作品

本研究システムによって音声に朗読表現がついたか確かめるために、分析対象を決めた。分析対象とするテキストは、宮沢賢治作『銀河鉄道の夜 [16]』から引用したものに決定した (図 **14**)。選定理由として、登場人物の心情描写や台詞、人物同士の対話が程よく含まれていると感じた。また感情の移り変わりがある描写も含まれており、朗読らしい表現が現れやすいテキストであるとも考えた。

5.2　手順

ず、VOICEPEAK 上にてテキスト入力をし、デフォルトのまま出力される合成音声を作成した。次に、本研究システムにて構築した一括変換機能にファイルを通し、保存された vpp ファイルから合成音声を出力した。さらに、これらの音声を聞いたうえで、筆者が気になった部分のみを手作業で調節した。これらの音声はゼミ研究室が持つ youtube のアカウントにて公開する。

5.3　朗読表現の簡易な操作（はどの程度できたのよ？）

自作する理由はここにあったはず．どれだけ「朗読」のために便利になったのか，事実を元に主張してみせるべし

5.4　複数解釈による朗読表現（はどの程度できたのよ？）

2.3 節で，朗読は複数話者の解釈で色々表現変わるんだと主張している以上，実際それをシステムでやってみるべし．

6. まとめ

上記までの修正に合わせて整える

本研究では、VOICEPEAK を土台としたうえで、豊かな表現のついた音声を出力するシステムの構築を図った。その結果、従来より豊かな表現力のついた合成音声を作り出すことができた。また、提供されている VOICEPEAK 上での不満点を本研究システムにて解消するように努め、その結果、VOICEPEAK 上では分からなかったパラメータ数値の表示をすることができ、より具体的な表現を指示ができるようになった。一方、vpp ファイルの書き換えのみではどうしてもできない部分も浮き彫りになった。例えば、内部ファイルのみでは作られている音声の再生が不可能であり、ユーザにフィードバックを与えられない点などが大きな課題点として挙げられた。また、短ポーズ (「、」) と長ポーズ (「。」) の区別が上手くいかず、全体でポーズの長さを設定するときは一律で変更されてしまう点なども挙げられた。

7. おわりに

謝辞

謝辞　書くならお好きに

参考文献

[1] 市川熹: 合成音声の自然性に関する実験的考察，日本音響学会講演論文集，pp. 95–96 (1967). https://cir.nii.ac.jp/crid/1572824499586773504.

[2] 【公式】窪田等の世界: 窪田等 朗読『走れメロス』作：太宰治, https://www.youtube.com/watch?v=YJe4D9JkouI (2020).

[3] 鳥海浩輔: 国語「鳥海浩輔が読む、太宰治『走れメロス』」【朗読】，https://www.youtube.com/watch?v=z9YW0xCIzWI (2021).

[4] Librosa, https://librosa.org/.

[5] 太宰治: 走れメロス，https://www.aozora.gr.jp/cards/000035/files/1567_14913.html.

[6] Zen, H., Senior, A. and Schuster, M.: Statistical Parametric Speech Synthesis Using Deep Neural Networks, *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*, Vancouver, BC, Canada, IEEE, pp. 7962–7966 (2013).

[7] 広瀬啓吉，高橋登，藤崎博也，大野澄雄: 音声の基本周波数パターンにおける話者の意図 感情の表現，信学技報， Vol. 94, pp. 33–40 (1994). https://cir.nii.ac.jp/crid/1570009752499942528.

[8] 飯田朱美, ニックキャンベル, 安村通晃: 感情表現が可能な合成音声の作成と評価, 情報処理学会論文誌，Vol. 40, No. 2, pp. 479–486 (1999). http://id.nii.ac.jp/1001/00012827/.

[9] AHS(AH-Software): VOICEPEAK 商用可能 6 ナレーターセット，https://www.ah-soft.com/voice/6nare/index.html.

[10] A.I.VOICE: A.I.VOICE, https://aivoice.jp/.

[11] Hello GPT-4o, https://openai.com/index/hello-gpt-4o/.

[12] 株式会社エーアイ: 音声合成 AITalk® とは?, https://www.ai-j.jp/about/.

© 2023-2025 Department of Informatics, The University of Fukuchiyama, Japan